

H4. 계절성과 분해

계절을 지우는 대신 꺼내서 보고, 관측을 추세 + 계절 + 잔차로 쪼갬다

지난 시간 복습 — H3

- 지난 시간(H3): 이동평균과 지수평활로 출렁임을 지웠다 — 특히 365일 창은 계절의 물결을 지우고 추세만 남겼다.
- 오늘은 지우는 대신 꺼내서 정면으로 본다 — "몇 월엔 보통 몇 도"의 목록을 만들고, 관측을 세 뿔으로 쪼갬다.
- 그리고 H2에서 z-점수가 "평범하다"고 넘긴 한여름의 22°C(태풍 카눈)가 오늘 마침내 잡힌다.

오늘의 목표

- groupby로 계절성 프로파일("몇 월엔 보통 몇 도")을 만들 수 있다.
- 값의 특별함을 값 자체가 아니라 그 시기의 보통과의 차이(편차)로 잴 수 있다.
- 관측을 추세 + 계절 + 잔차로 분해하고, 각 몫의 크기를 비교할 수 있다.
- 잔차가 "버리는 것"이 아니라 무엇의 기록인지 말할 수 있다.

손으로 워밍업 — 분식집의 2주

어느 분식집의 하루 손님 수. (단위: 명)

	월	화	수	목	금	토	일
1주차	42	45	43	47	71	95	88
2주차	44	43	46	49	75	99	91
요일 평균	43		44.5	48			89.5

- **요일 평균:** 그 요일의 "보통". 월요일 칸은 $(42 + 44) \div 2 = 43$. 빈 칸은 활동지에서 채운다.
- 평일은 40명대, 주말은 90명 안팎 — 손님 수에 요일의 리듬이 있다.

값의 특별함은 보통과의 차이로 잰다

- 3주차 금요일에 90명이 왔다. 많이 온 것인가? — 90이라는 숫자만 봐서는 모른다. 금요일의 보통과 비교해야 한다.
- 같은 90명이 토요일에 왔다면 이야기가 달라진다 — 관측값이 같아도 비교 상대가 다르면 소식이 다르다.
- 이 차이를 편차(anomaly)라 부르고, 요일이든 계절이든 일정한 주기로 되풀이되는 "보통"의 패턴을 계절성(seasonality)이라 부른다. 기온의 계절성은 1년짜리 물결이다.

코드로 — 준비와 데이터 불러오기

준비(한글 글꼴)와 데이터는 H3과 같다:

```
!pip install -q koreanize-matplotlib
import koreanize_matplotlib
```

```
import pandas as pd

url = "https://raw.githubusercontent.com/jaehoonkim/timeseries-academy/main/data/seoul-temp-daily.csv"
df = pd.read_csv(url, parse_dates=["date"], index_col="date")
t = df["temp_avg"]
```

groupby 읽는 법 — 달마다의 평균

1절의 "요일 평균"을 기온에서는 "달마다의 평균"으로 만든다.

```
t.groupby(t.index.month).mean()
```

= t의 1,096일을 / 월 번호(1~12)가 같은 날끼리 묶어(groupby) /
묶음마다 평균(mean)을 구하라

(t.index.month 는 날짜 인덱스에서 월 번호만 꺼낸 것)

```
profile = t.groupby(t.index.month).mean()  
profile
```

- 1,096일이 12줄로 줄었다 — 요약이다.

계절성 프로필 — 몇 월엔 보통 몇 도

```
profile.plot(label="월별 보통", legend=True)
```

- 12개 점으로 그린 이 곡선이 서울 기온의 계절성 프로필이다.
- 그래프는 모양을 보는 용도 — 어느 달이 꼭대기이고 바닥인지.
- 정확한 숫자는 그래프가 아니라 **12줄 표**에서 읽는다. 특히 이웃한 달의 근소한 차이는 곡선에서는 눈으로 구분되지 않는다 — 직감을 확인하려면 그림이 아니라 숫자 목록을 봐야 한다.

편차 — 날마다 저마다의 보통과 비교한다

이제 1,096일 하루하루에 대해 "그날 기온이 그날이 속한 달의 보통보다 몇 도 높거나 낮았나"를 계산한다.

- 8월의 어느 날이 30.1°C 였다면 비교 상대는 프로필의 8월 값 26.7°C — 편차 **+3.4**, 조금 더운 날.
- 1월의 어느 날이 -10.0°C 였다면 비교 상대는 1월 값 -3.2°C — 편차 **-6.8**, 꽤 특별한 한파.
- 모든 날이 하나의 공통 기준과 비교되는 게 아니라, 날마다 자기 달의 프로필 값을 저마다의 기준으로 받는다 — 금요일의 90명을 "금요일의 보통"과 비교했던 것과 같은 이치다.

transform 읽는 법 — 12줄을 1,096일 자리로

```
t.groupby(t.index.month).transform("mean")
```

= 같은 달끼리 묶어 평균을 내되 / 요약하지 말고 그 평균을
1,096일 원래 자리마다 되돌려 놓아라(transform)

- `mean()` 과 `transform("mean")` 은 계산이 같고 모양만 다르다:
`mean()`은 12줄 요약, `transform`는 1,096줄 그대로 — 1월의 모든
날에 1월 평균이, 8월의 모든 날에 8월 평균이 적힌다.

profile (12줄)

1월 -3.2

...

8월 26.7

...

monthly (1,096줄)

2023-01-01 -3.2

2023-01-02 -3.2

...

2023-08-10 26.7

...

(1월의 모든 날에 -3.2)

(8월의 모든 날에 26.7)

왜 12줄이면 안 되나 — 뽕셈은 자리끼리

```
monthly = t.groupby(t.index.month).transform("mean")  
a = t - monthly  
a.plot(label="편차", legend=True)
```

- 핵심이 `t - monthly`, 즉 뽕셈이기 때문이다. 뽕셈은 같은 날짜 자리끼리 짝을 지어 이루어지므로, `t`에서 빼려면 빼는 쪽도 날짜별 1,096줄이어야 한다.
- `a`가 1절의 편차다: 그날 기온이 그 달의 보통보다 몇 도 높거나 낮았는가. 편차 그래프에서 계절의 물결이 어떻게 됐는지, 세로축과 `a.std()`로 직접 확인해 보자.

카눈의 재발견 — 비교 대상을 바꾸면

- H2에서 태풍 카눈이 온 2023-08-10(22.0°C)의 z-점수는 +0.85 — "오히려 따뜻한 평범한 날"이었다.
- z-점수의 비교 상대는 3년 전체(겨울 포함)의 평균이었다.
한여름의 22°C는 그 기준으로는 평범하다.
- 편차의 비교 상대는 8월의 보통이다 — 같은 22°C가 어떻게 보일지, 활동지에서 `a.loc["2023-08-10"]` 로 직접 확인한다.
- 비교 대상을 바꾸면 안 보이던 이상함이 보인다.

분해 — 관측 = 추세 + 계절 + 잔차

- 3절의 "보통"은 3년 내내 같다고 가정했다. 그런데 H3에서 연평균이 오르는 중임을 봤다 — 보통 자체가 천천히 움직인다.
- 그래서 관측을 세 몫으로 쪼갬다:

관측 = 추세 + 계절 + 잔차

추세(trend): 천천히 움직이는 배경 수준 /

계절: 해마다 반복되는 물결 /

잔차(residual): 둘로 설명되지 않은 나머지

추세 — 365일 중심 창

추세는 H3에서 이미 만들었다 — 365일 창은 계절을 지운다. 단, 이번엔 창을 중심에 놓는다:

```
trend = t.rolling(window=365, center=True).mean()  
trend.plot(label="추세", legend=True)
```

- 왜 후행 창이 아니라 `center=True` 일까? — 후행 7일 창이 5일 늦었던 것(H3)을 떠올리며 활동지에서 답해 보자.
- `trend.isna().sum()` 으로 NaN이 며칠인지도 확인한다 — 중심 창의 대가다.

계절과 잔차 — 남김없이, 이중으로 세지 않고

```
detr = t - trend
seasonal = detr.groupby(detr.index.month).transform("mean")
resid = t - trend - seasonal
```

- 계절은 3절의 프로필을 다시 쓰되, 추세 몫을 먼저 걷어낸 나머지(detr)에서 계산한다 — 같은 양을 두 몫에 이중으로 세지 않기 위해서다.
- 잔차는 남은 전부다 — 정의상 관측 = 추세 + 계절 + 잔차가 정확히 성립한다.

세 뭉의 키 재기

원본과 세 뭉을 각각 그려서 세로축을 비교한다:

```
t.plot(label="관측", legend=True)
trend.plot(label="추세", legend=True)
seasonal.plot(label="계절", legend=True)
resid.plot(label="잔차", legend=True)
```

(넉 장을 따로 — H3에서 배웠듯 축부터 읽는다)

- 세 뭉이 움직이는 폭은 서로 크게 다르다. 서울 기온의 출렁임은 대부분 어느 뭉인지, 세로축에서 직접 읽어 보자.

재조립 — 설명한 것과 남은 것

```
t.plot(label="관측", legend=True)  
(trend + seasonal).plot(label="추세+계절", legend=True)
```

- 추세와 계절을 도로 더하면 "모형이 설명하는 부분"이 된다.
- 원본의 표준편차 11.0이 잔차에서는 얼마나 줄었는지
 `resid.std()` 로 확인하자 — "서울의 하루 기온은 무엇이 대부분 결정하고, 날씨 사건이 몇 도쯤 엇히는지"가 숫자로 나온다.
- 잔차의 바닥을 찾아가 보면(2026년 1월) 낮익은 사건을 다시 만난다 — 잔차는 쓰레기가 아니라 모형 밖 사건의 기록이다.

'보통'의 진짜 이름들

'보통'은 통계학의 공식 용어가 아니다 — 하지만 가는 곳마다 공식 이름이 있다.

분식집에서는 요일 평균, 프로필에서는 프로필,
기상학에서는 평년(normal), 분해에서는 계절 몫
(통계학에서는 조건부 평균(conditional mean))

- 이름이 무엇이든 하는 일은 하나: **비교의 기준선**이 되는 것.
- 기준선이 서면 남는 것은 언제나 편차다 — 기후 뉴스의 "산업화 이전 대비 +1.5°C"가 바로 우리가 만든 **a** 와 같은 물건이다.

평균으로 잡은 것도 하나의 선택이다

- 기온은 한 달 안의 값들이 평균 둘레에 고르게 퍼져 있어서 평균이 '보통'의 감각과 잘 맞는다.
- 하지만 분식집 매출처럼 어쩌다 대박이 섞이는 데이터라면 평균은 대박 쪽으로 끌려가서 "보통 날"보다 큰 값이 된다 — 그럴 때는 줄 세워 한가운데를 잡는 중앙값(median)이 '보통'에 더 가깝다.
- 무엇으로 기준선을 세울지도 데이터를 보고 고르는 것이다.

오늘 배운 세 문장

1. 특별함은 값 자체가 아니라 그 시기의 보통과의 차이(편차)로
 잔다.
2. 관측 = 추세 + 계절 + 잔차 — 서울 기온은 계절 몫이 압도한다.
3. 잔차는 쓰레기가 아니라 모형 밖 사건의 기록이다.

이제 활동지로

1. 분식집 표에서 요일 평균을 손으로 채우고, 같은 90명이 요일에 따라 다른 소식이 되는 이유를 쓴다.
2. `groupby`로 계절성 프로필을 만들고, 표에서 가장 더운 달과 추운 달을 읽는다.
3. `transform`으로 편차를 만들고, 카눈(2023-08-10)을 편차로 다시 본다.
4. 365일 중심 창으로 분해를 완성하고, 세 몫의 키를 비교한다.
5. 재조립으로 `resid.std()`를 확인하고, 잔차의 바닥에서 낮익은 사건을 찾는다.