

## H8. 미니 프로젝트

내 데이터로, 처음부터 끝까지

## 지금까지 배운 것 — 도구 상자 지도

1. H1. 시계열과 파이썬 — 본다
2. H2. 분포로 보는 시계열 — 재고, 튀는 값을 의심한다
3. H3. 평활 — 매끈하게 편다
4. H4. 계절성과 분해 — 쪼갬다 (프로필과 편차)
5. H5. 자기상관 — 어제와 오늘의 닮음을 잴다
6. H6. 예측과 평가 — 규칙과 심판을 세운다
7. H7. 회귀로 예측 — 도전자를 만든다
8. H8. 미니 프로젝트 ← 오늘

오늘은 새로 배우는 게 없다. 대신 위 일곱 가지를 전부 쓴다.

## 오늘의 목표

- 서울 기온이 아니라 내가 고른 데이터로 전 과정을 완주한다.
- 완주의 두 축(H7 예고 그대로):
  - i. 내 데이터의 "달의 보통"은 무엇인가 — 리듬(주기)을 찾아 재료로 만든다.
  - ii. **naive**를 이겼는가 — 벽의 높이를 재고, 규칙을 지키며 도전한다. "이겼다"보다 중요한 것은 **규율**이다.
- 결과를 다섯 장으로 발표한다 — 그래프 한 장 = 발견 한 개.

## 항해 지도 — 일곱 걸음

질문 → 데이터 준비 → 본다(H1·H2) → 리듬·관성을 잔다(H4·H5)  
→ 규칙과 심판(H6) → 도전자(H7) → 발표

- 지난 일곱 시간은 이 걸음을 기온 데이터 하나로, 정해진 순서대로 연습한 것이었다.
- 오늘부터는 데이터도, 질문도, 걸음을 밟는 것도 각자(또는 팀)의 몫이다. 활동지가 항해 일지다 — 걸음마다 기록을 남긴다.

# 1걸음 — 질문 정하기

좋은 시계열 질문의 세 가지 조건:

1. 시간에 따라 변하는 숫자인가? (날짜 + 값)
2. 데이터를 구할 수 있는가?
3. 내가 정말 궁금한가? (발표까지 끌고 갈 연료)

질문 예시: "우리 동네 미세먼지는 겨울에 정말 나쁠까 — 내일 농도를 회귀로 맞힐 수 있을까?", "내 걸음 수에서 naive는 벽일까, 만만한 상대일까?"

그리고 예감 한 줄: 내 데이터의 "달의 보통" 자리에는 무엇이 올까? — 기온은 달, 분식집은 요일이었다(H7 Q15).

## 데이터의 기간 조건 — 이번엔 둘

- 패턴은 두 번 반복되어야 패턴이다(H4) — 요일 리듬이 궁금하면 최소 한 달, 월 리듬이 궁금하면 2년 이상.
- 홀드아웃 뭉(H6) — 뒤쪽 1/3을 시험으로 떼어도 훈련이 남아야 한다. **90행** 이상 권장(훈련 60 + 시험 30), 연 리듬까지 보려면 2년 + 1년이 이상적.
- 조건에 안 맞으면 질문을 데이터에 맞게 줄인다("연 리듬" → "요일 리듬").

## 데이터 후보 (모두 무료)

| 데이터          | 어디서                         | 주기        |
|--------------|-----------------------------|-----------|
| 우리 동네 기온·강수량 | 기상자료개방포털 data.kma.go.kr     | 일별        |
| 검색어 관심도      | 네이버 데이터랩 / 구글 트렌드           | 일·주별      |
| 내 걸음 수·스크린타임 | 스마트폰 건강 앱                   | 일별        |
| 미세먼지, 한강 수위  | 서울 열린데이터광장 data.seoul.go.kr | 일·시간별     |
| 물가지수, 인구     | KOSIS kosis.kr              | 월별        |
| 주가·환율        | 증권사·한국은행                    | 일별(난도 최상) |

막히면 백업 데이터를 준다 — 수집이 아니라 분석·발표가 본체다.

## 2걸음 — 데이터 준비 (Colab)

```
import pandas as pd

df = pd.read_csv("내파일.csv", parse_dates=["날짜열"], index_col="날짜열")
v = df["값열"]
```

- CSV 한글이 깨지면 `encoding="cp949"` (공공데이터 최다 빈출).
- 그래프 한글이 □면 `koreanize` 준비 셀부터(H3부터 쓴 그대로).
- 날짜가 안 읽히면 손 들 것 — 형식 지정 한 줄로 해결된다.
- 첫 점검 3종: 행 수, 기간, 결측 개수. 결측은 채우기 전에 왜 비었는지부터 — 주말마다 비면 결측이 아니라 "원래 없는 날"이다.



### 3걸음 — 본다 (H1·H2)

- `v.plot()` — 전체 모양: 기온 같은 물결? 오르막? 들쭉날쭉?
- `v.describe()` — 상식적인 범위인가?
- z-점수로 튀는 날 찾기: `z[abs(z) > 2]` — 후보가 많으면 3으로 올려 극단만.
- 튀는 날은 지우기 전에 원인부터(H2). 오타면 고치고, 사건이면 지울 게 아니라 발표 재료다.

## 4걸음 — 리듬과 관성을 잔다 (H4·H5)

여기서 잔 두 가지가 승부를 좌우한다:

- 리듬(프로필) — 후보 주기마다 `groupby` 프로필을 만들어 굴곡을 본다. 재료의 정보량은 프로필의 굴곡이다(H7):  
뚜렷하면 살아 있는 재료, 평평하면 죽은 재료.
- 관성(자기상관) — `v.autocorr(1)` . 이 숫자가 **naive** 벽의 높이를 예언한다. 기온은 0.98이라 naive가 벽이었다 — 내 데이터가 훨씬 작다면 승부는 다르게 흘러간다.

예감을 적어 두고 다음 걸음에서 확인하자.

## 5걸음 — 규칙과 심판 (H6)

- 분할: 뒤쪽 1/3이 시험. 분할 날짜를 향해 일지에 적는다.
- 심판: MAE·RMSE 둘 다.
- 벽부터: 도전자보다 먼저 naive를 채점한다 — 이 성적이 넘어야 할 벽의 높이다.

```
data = pd.DataFrame({"어제": v.shift(1), "오늘": v}).dropna()  
train = data[:"분할날짜"]; test = data["분할다음날":]  
e_naive = test["오늘"] - test["어제"]  
e_naive.abs().mean(), (e_naive**2).mean() ** 0.5
```

벽의 높이가 4걸음의 자기상관과 맞는 그림인지 확인할 것.

## 6걸음 — 도전자를 만든다 (H7)

- 특징 테이블: 어제 + 살아 있던 프로필. 프로필은 훈련 구간에서만 계산한다(시험을 미리 보면 반칙).
- fit → 계수를 배합 문장으로 읽는다 — 기온의 "어제 80% + 보통 20%"와 같은가, 뒤집혔는가? 배합은 데이터가 정한다.
- 어디서 벌었는지 — 어느 달에서 naive보다 오차를 줄였는지 — 월별(내 주기별)로 쪼갬다.
- 재료 실험 한 가지 이상. 단 세 가지 반칙 주의:
  - i. 프로필을 전체 데이터로 계산 (훈련만!)
  - ii. 시험 성적을 보며 재료 조합 고르기 (조합도 훈련 성적으로)
  - iii. 시험 성적이 만점에 가까우면 — 기빠 말고 새는 재료부터 의심(만점 = 반칙 신호)

## 발표 — 5분 다섯 장

그래프 한 장 = 발견 한 개.

1. 내 질문 — 한 문장.
2. 데이터 소개 — 출처, 기간, 행 수, 결측 처리.
3. 발견 셋 — 리듬(프로필)과 자기상관은 꼭. 이 데이터의 성격 소개다.
4. 승부 — naive의 벽(높이와 이유) → 도전자의 성적과 배합 → 어디서 벌었나.
5. 한계와 다음 재료 — 전환점은 맞혔나? 못 맞혔다면 어떤 원인 재료가 필요할까(기상청이 기압·바람을 보는 이유).

## 발표의 태도

- 잘 나온 결과만 보여줄 필요 없다 — 안 나온 리듬, naive에 진 성적, "판단 불가"도 정직한 발견이다.
- naive를 못 이겼어도 그 이유(높은 자기상관, 죽은 재료)를 설명하면 훌륭한 발표다. "이겼다" 한마디보다 "어디서 얼마나 깎았다"가 이 과정의 문장.
- 청중 규칙: 발표마다 질문 하나 — "그 튀는 값은 무슨 일이었나요?", "프로필은 훈련 구간으로만 계산했나요?", "naive는 이겨 봤나요 — 어디서 벌었나요?"

# 무엇을 보고 판단하나

발표에서 눈여겨보는 항목:

- 질문이 데이터로 답할 수 있게 분명한가.
- 출처·기간·행 수·결측을 제대로 설명했는가.
- 프로필 굴곡과 자기상관으로 데이터의 성격을 소개했는가.
- 튀는 값의 원인을 찾아봤는가.
- 벤치마크 규율 — naive 채점, 훈련만으로 프로필·조합, 홀드아웃 준수.
- 배합 문장과 "어디서 벌었는지"까지 읽었는가.
- 한계와 다음 재료를 스스로 짚었는가.

## 이제 활동지로

1. 질문과 예감("달의 보통 자리에 무엇이?")을 적고 데이터를 고른다.
2. CSV를 불러와 첫 점검(행 수·기간·결측)을 한다.
3. 그래프·분포·z-점수로 보고, 튀는 날의 원인을 찾는다.
4. 프로필의 굴곡과 자기상관을 재고, 벽의 높이를 예감한다.
5. 분할하고 naive를 채점한다 — 벽이 섰다.
6. 회귀 도전자를 만들어 배합을 읽고, 어디서 벌었는지 본다.
7. 다섯 장으로 발표한다 — 여덟 모듈의 완주다.