

U7. 특징 기반 ML 도전

도전자의 날 — 그리고 과정 전체의 결론 문장

지난 시간 복습 — 그리고 외상 장부

- U6까지 고전 가족의 여정이 끝났다 — 지하철의 복수전(SARIMA 37.9만), 예측을 따로 말하는 법.
- 그러나 장부에 외상이 남아 있다: 명절 급락은 아무도 못 맞혔다(U1 Q10). 오차의 원인은 "그날이 빨간 날인가"라는 달력 정보인데(U4 Q6), 고전 가족은 전부 값의 과거만 본다.

오늘의 목표 — 그리고 예고

- 도전자 특징 기반 ML을 두 무대(기온·지하철)에 세워 고전의 챔피언들과 대결시킨다 — 결과가 과정 전체의 결론 문장이 된다.
- 예고: 오늘도 산이 아니다. 새 도구는 셋(표 만들기·부스팅·교차검증), 코드의 절반은 아는 도구(shift·dayofweek·rolling)의 재조립이다.

발상 — 시계열을 표로

- 각 날짜를 표의 한 줄로: 그날 예측에 쓸 재료들(열)과 그날의 정답. 재료 열 하나하나가 특징(feature)이다.
- 재료 세 갈래, 전부 구면: 과거의 값(shift), 달력(dayofweek), 최근 평균(rolling).
- 반칙 방지 하나만 새로 챙긴다: 최근 평균은 하루 밀어서 — 안 밀면 오늘의 정답이 재료에 섞인다. (달력 특징은 밀 필요 없음 — 미래 것도 원래 아는 정보다.)

도전자 — 그래디언트 부스팅

- 정식 이름 그래디언트 부스팅(gradient boosting) — 실무.
검색에서는 부스팅 트리, GBDT, XGBoost·LightGBM. 이 과정의
별명은 부스팅 나무.
- 작은 결정 트리("어제가 20도보다 높은가?" 갈래 질문 몇 개짜리)
수백 그루를 차례로, 새 나무는 앞 나무들이 남긴 오차를
깎도록 심는다.
- 임의로 고른 모형이 아니다 — 표 데이터에서 지난 10년 실무와
대회의 표준(시계열 최대 대회 M5의 우승 계열)이다.

핵심 원리 — 질문은 열에서만 나온다

- 나무의 갈래 질문은 표의 열에서만 만들 수 있다. 같은 재료를 받은 날들은 같은 예측을 받는다.
- 훈련에 명절 급락이 서른세 번 있어도, 그 날들을 갈라낼 열이 없으면 그 오차를 깎을 나무를 심을 수 없다.
- 그래서 오늘의 한 문장: 모형의 힘은 알고리즘이 아니라 질문할 수 있는 재료의 목록이 정한다.

세 층의 분업 — 과정의 그 구조

- 방법(관련성을 찾고 쓰는 절차) = 모델 선택에 고정.
- 재료(표의 열 = 찾을 수 있는 관련성의 한계) = 사람이.
- 내용(실제로 찾아낸 관련성) = 데이터가.
- "부품은 사람이, 배합은 데이터가"(U4·U5)의 ML판 — 특징 기반 가족은 재료의 자유도만 폭발적으로 커진 것이다.
- 주의: 모형이 찾는 것은 '이유'가 아니라 '관련성'이다 — 이유를 아는 것은 사람의 몫이고, 그래서 특징 설계가 사람의 일이다.

무대 1 — 기온

선수	하루 앞 MAE (°C)
naive (U1)	1.63
Holt-Winters (U4)	1.55
ARIMA(2,1,1) (U5)	1.53
부스팅 (특징 5개)	?

- 도전자는 이 벽들을 넘을 수 있는가 — 활동지에서 채점한다.
결과는 오늘의 결론에 필요한 반쪽이다.

무대 2 — 지하철, 달력을 손에 쥐다

- 1라운드: 어제·지난주·요일까지 — SARIMA(37.9만)를 이길 수 있는가?
- 2라운드: 고전이 절대 가질 수 없는 열을 넣는다 — 기간 안 평일의 빨간 날 목록. 데이터가 아니라 달력에서 온 정보라 시험 기간 것을 미리 알아도 반칙이 아니다.
- 채점표에서 U1의 그 독법을 꺼내 보라 — 두 심판의 간극이 무엇을 말하는지.

심판을 여러 번 — rolling-origin 교차검증

- 시험 성적으로 특징을 고르면 시험지가 훈련지가 된다 — 반칙.
고전에는 AIC가 있었지만 ML에는 없다.
- ML의 심판: 훈련 안에서 가짜 시험을 여러 번 — 앞부분으로 배우고 다음 토막을 맞히기를, 시작점을 밀며 반복(rolling origin). 무작위로 섞지 않는 것이 시계열 교차검증의 전부다.
- U8의 작업 순서가 이것이다: 심판으로 특징을 고른 뒤에 시험지를 연다.

결론 — 두 세계의 승자

- 두 무대의 우승자가 갈린다 — 어느 쪽이 어떻게 갈리는지는 활동지의 몫.
- 도착할 문장은 미리 적어 둔다: 모형에 우열이 있는 것이 아니라, 데이터의 성격이 승자를 고른다.
- 기온은 관성의 세계, 지하철은 달력의 세계 — 이 문장이 과정 전체의 결론이고, 다음 주 각자의 데이터에서 스스로 판별하게 된다.

오늘의 세 문장

1. 특징이 발상이다 — 시계열을 표로 바꾸면 어떤 모형이든 쓸 수 있고, 표를 만든 도구는 전부 $U1 \cdot U2$ 의 재조립이다.
2. 승자는 데이터마다 갈린다 — 관성의 세계는 고전이, 달력의 세계는 달력을 쥔 도전자가 이긴다.
3. ML의 심판은 **rolling-origin** 교차검증이다 — 훈련 안에서 가짜 시험을 여러 번, 시험지는 마지막에 한 번.

이제 활동지로

1. 기온의 특징 표를 만든다 — 반칙 방지 장치(shift)를 점검한다.
2. 도전자를 기온 무대에 세운다 — 벽을 넘는가.
3. 지하철 2라운드 — 빨간날 열이 판을 어떻게 바꾸는지, RMSE 간극으로 읽는다.
4. 교차검증으로 같은 결론에 시험지 없이 도달할 수 있었는지 확인한다.
5. 두 순위표를 나란히 놓고 과정의 결론 문장을 적는다 — 그리고 내 데이터는 어느 세계인지 생각한다.